


Reti neurali

Componenti della rete (a livelli)

Si considera una rete neurale costituita di strati (livelli) di unità collegate a tutte e soltanto le unità del livello precedente. Il primo livello riceve i valori in ingresso, l'ultimo produce quelli in uscita.

- Unità: su livello i (precedente) e livello j (attuale)
- Attività dell'unità: y_j
- Pesì: w_{ij} del collegamento tra l'unità j ed le unità i precedenti.



- Ingresso complessivo dell'unità j : $x_j = \sum_i w_{ij} \cdot y_i$ [1]
- Funzione di attivazione $F(x)$ e attività dell'unità; $y_j = F(x_j)$ [2]
- Derivata dell'attività all'ingresso complessivo; $\frac{dy_j}{dx_j} = F'(x_j)$ [3]
- Uscita desiderata: d_j [4]

Errore complessivo e dipendenze

- Errore complessivo delle unità di uscita:

$$E = \frac{1}{2} \cdot \sum_j (y_j - d_j)^2 = \frac{1}{2} \cdot \sum_j \beta_j^2 \quad [5]$$

- Derivata dell'errore totale al variare dell'attività dell'unità di uscita j :

$$EA_j = \beta_j = \frac{\partial E}{\partial y_j} = y_j - d_j \quad [6]$$

- Derivata dell'errore totale al variare dell'ingresso x_j dell'unità j , con la [6] e la [2]:

$$EI_j = \frac{\partial E}{\partial x_j} = \frac{\partial E}{\partial y_j} \cdot \frac{dy_j}{dx_j} = \beta_j \cdot F'(x_j) \quad [7]$$


- Derivata dell'errore totale al variare del peso w_{ij} del collegamento tra l'unità j e l'unità i del livello precedente:

$$EW_{ij} = \frac{\partial E}{\partial w_{ij}} = \frac{\partial E}{\partial x_j} \cdot \frac{\partial x_j}{\partial w_{ij}} = \beta_j \cdot F'(x_j) \cdot y_i = EI_j \cdot y_i \quad [8]$$

- Derivata dell'errore totale al variare dell'attività dell'unità i del livello precedente (con la [7] e la [1]):

$$EA_i = \beta_i = \frac{\partial E}{\partial y_i} = \sum_j \frac{\partial E}{\partial x_j} \cdot \frac{\partial x_j}{\partial y_i} = \sum_j EI_j \cdot w_{ij} = \sum_j \beta_j \cdot F'(x_j) \cdot w_{ij} = \sum_j EI_j \cdot w_{ij} \quad [9]$$

L'unità i è connessa alle unità j del livello successivo, che contribuiscono tutte, sommate, all'errore totale E .



Funzioni di attivazione

Funzioni di attivazione (https://it.wikipedia.org/wiki/Funzioni_di_attivazione), con derivate semplici

- Sigmoide: $F = \frac{1}{1+e^{-x}}$ [2a]

$$F' = \frac{e^{-x}}{(1+e^{-x})^2} = \frac{(1+e^{-x})-1}{(1+e^{-x})^2} = \left(1 - \frac{1}{1+e^{-x}}\right) \left(\frac{1}{1+e^{-x}}\right) = F \cdot (1-F) \quad [3a]$$

- Tangente iperbolica: $F = \tanh x = \frac{e^x - e^{-x}}{e^x + e^{-x}}$ [2b]

$$F' = (-1) \cdot \frac{(e^x - e^{-x}) \cdot (e^x - e^{-x})}{(e^x + e^{-x})^2} + \frac{1}{e^x + e^{-x}} \cdot (e^x - (-1) \cdot e^{-x}) = \frac{(e^x + e^{-x})^2 - (e^x - e^{-x})^2}{(e^x + e^{-x})^2} = \dots$$

$$\dots = 1 - \frac{(e^x - e^{-x})^2}{(e^x + e^{-x})^2} = 1 - F^2 \quad [3b]$$

- Rettificatore unità lineare ReLU: $F = \max(0, x)$ [2c]

$$F' = \begin{cases} 0 & \forall x < 0 \\ 1 & \forall x > 0 \end{cases} \quad [3c]$$

Algoritmo di back-propagation

L'addestramento della rete è affrontato qui per mezzo di algoritmi, trascurando al momento il calcolo matriciale, usato in varie librerie (Torch, TensorFlow, ML, OpenNN...).

- Costante di apprendimento δ
- Finché la rete non è addestrata, ripetere le successive operazioni per ogni configurazione.
- Calcolare, dagli ingressi del primo livello in poi, le uscite y di tutti i livelli (forward-propagation), con le formule [1] e [2].
- Calcolare le β_j delle unità di uscita, con la formula [6].
- Calcolare le β di tutti i livelli (dall'ultimo al primo), con la formula [9].
- Calcolare l'influenza $\frac{\partial E}{\partial w_{ij}} = EI_j \cdot y_i$ di ogni peso sull'errore totale, con la formula [8].
- Correggere ogni peso del valore: $\Delta w_{ij} = -\delta \cdot \frac{\partial E}{\partial w_{ij}}$ [10]

Cicli di calcolo

- La forward-propagation ricalcola i livelli dal primo all'ultimo, valutando, per ogni unità, le x_j , $F(x_j)$, $F'(x_j)$ ed y_j (e azzerando le β_j). Il calcolo della [1] viene eseguito una volta per ogni unità, con un ciclo sulla lista dei pesi dei collegamenti dell'unità j con le unità precedenti i .
- Per la back-propagation, il calcolo delle β_i , con la [9], richiede un ciclo su tutti i collegamenti dell'unità i con le unità successive j : se le unità contengono la lista dei collegamenti alle precedenti (e non alle successive), conviene eseguirlo in altro modo.
- Si esegue il calcolo su tutti i livelli j , partendo dall'ultimo.
 - Al livello j le β_j sono note dalla formula [6] (per l'ultimo livello) o dal calcolo del livello j eseguito precedentemente.
 - Sul livello j , si calcolano i termini $EI_j = \beta_j \cdot F'(x_j)$ formula [7]), essendo noti i valori di x_j e y_j dalla forward-propagation.
 - Per ogni nodo del livello j si esegue un ciclo sulle sinapsi ai nodi i del livello precedente, calcolandone il contributo $\beta_i^j = EI_j \cdot w_{ij}$ ai valori β_i della [9]. Nella formula [9] i valori EI_j sono già stati calcolati. I contributi β_i^j possono essere sommati alle β_i , perché tutte le β erano state azzerate nella forward-propagation.
 - Al termine del ciclo sui nodi del livello j , i nodi del livello precedente conterranno i valori β_i completi.
 - Note le $\beta_i \equiv \beta_{j-1}$ del livello precedente, si ripete il ciclo sul livello $j \leftarrow j - 1$.

- Note le EI di tutti i nodi, si correggono, per ogni nodo j , i pesi dei collegamenti con i nodi i del livello precedente con la formula [10]: $\Delta w_{ij} = -\delta \cdot \frac{\partial E}{\partial w_{ij}} = -\delta \cdot EI_j \cdot y_i$. Il calcolo non dipende dai pesi w ma solo dai valori di EI e di y dei nodi, quindi può essere eseguita su tutte le sinapsi di un nodo in parallelo.