


# Reti neurali

## Componenti della rete (a livelli)

Si considera una rete neurale costituita di strati (livelli) di unità collegate a tutte e soltanto le unità del livello precedente. Il primo livello riceve i valori in ingresso, l'ultimo produce quelli in uscita.

- Unità: su livello  $i$  (precedente) e livello  $j$  (attuale)
- Attività dell'unità:  $y_j$
- Pesì:  $w_{ij}$  del collegamento tra l'unità  $j$  ed le unità  $i$  precedenti.



- Ingresso complessivo dell'unità  $j$ :  $x_j = \sum_i w_{ij} \cdot y_i$  [1]
- Funzione di attivazione  $F(x)$  e attività dell'unità:  $y_j = F(x_j)$  [2]
- Derivata dell'attività all'ingresso complessivo;  $\frac{dy_j}{dx_j} = F'(x_j)$  [3]
- Uscita desiderata:  $d_j$  [4]

## Errore complessivo e dipendenze

- Errore complessivo delle unità di uscita:  $E = \frac{1}{2} \cdot \sum_j (y_j - d_j)^2 = \sum_j \beta_j^2$  [5]
- Derivata dell'errore totale al variare dell'attività dell'unità di uscita  $j$ :


$$EA_j = \beta_j = \frac{\partial E}{\partial y_j} = y_j - d_j \quad [6]$$

- Derivata dell'errore totale al variare dell'ingresso  $x_i$  dell'unità  $j$ , con la [6] e la [2]:

$$EI_j = \frac{\partial E}{\partial x_j} = \frac{\partial E}{\partial y_j} \cdot \frac{dy_j}{dx_j} = \beta_j \cdot F'(x_j) \quad [7]$$

- Derivata dell'errore totale al variare del peso  $w_{ij}$  del collegamento tra l'unità  $j$  e l'unità  $i$  del livello precedente:

$$EW_{ij} = \frac{\partial E}{\partial w_{ij}} = \frac{\partial E}{\partial x_j} \cdot \frac{\partial x_j}{\partial w_{ij}} = \beta_j \cdot F'(x_j) \cdot y_i = EI_j \cdot y_i \quad [8]$$



- Derivata dell'errore totale al variare dell'attività dell'unità  $i$  del livello precedente (con la [7] e la [1]):

$$EA_i = \beta_i = \frac{\partial E}{\partial y_i} = \sum_j \frac{\partial E}{\partial x_j} \cdot \frac{\partial x_j}{\partial y_i} = \sum_j EI_j \cdot w_{ij} = \sum_j \beta_j \cdot F'(x_j) \cdot w_{ij} = \sum_j EI_j \cdot w_{ij} \quad [9]$$

L'unità  $i$  è connessa alle unità  $j$  del livello successivo, che contribuiscono tutte, sommate, all'errore totale  $E$ .

## Funzioni di attivazione

Funzioni di attivazione ([https://it.wikipedia.org/wiki/Funzioni\\_di\\_attivazione](https://it.wikipedia.org/wiki/Funzioni_di_attivazione)), con derivate semplici

- Sigmoide:  $F = \frac{1}{1+e^{-x}}$  [2a]

$$F' = \frac{e^{-x}}{(1+e^{-x})^2} = \frac{(1+e^{-x})-1}{(1+e^{-x})^2} = \left(1 - \frac{1}{1+e^{-x}}\right) \left(\frac{1}{1+e^{-x}}\right) = F \cdot (1-F) \quad [3a]$$

- Tangente iperbolica:  $F = \tanh x = \frac{e^x - e^{-x}}{e^x + e^{-x}}$  [2b]

$$F' = (-1) \cdot \frac{(e^x - e^{-x}) \cdot (e^x - e^{-x})}{(e^x + e^{-x})^2} + \frac{1}{e^x + e^{-x}} \cdot (e^x - (-1) \cdot e^{-x}) = \frac{(e^x + e^{-x})^2 - (e^x - e^{-x})^2}{(e^x + e^{-x})^2} = \dots$$

$$\dots = 1 - \frac{(e^x - e^{-x})^2}{(e^x + e^{-x})^2} = 1 - F^2 \quad [3b]$$

- Rettificatore unità lineare ReLU:  $F = \max(0, x)$  [2c]

$$F' = \begin{cases} 0 & \forall x < 0 \\ 1 & \forall x > 0 \end{cases} \quad [3c]$$

# Algoritmo di back-propagation

L'addestramento della rete è affrontato qui per mezzo di algoritmi, trascurando al momento il calcolo matriciale, usato in varie librerie (Torch, TensorFlow, ML, OpenNN...).

- Costante di apprendimento  $\delta$
- Finché la rete non è addestrata, ripetere le successive operazioni per ogni configurazione.
- Calcolare, dagli ingressi del primo livello in poi, le uscite  $y$  di tutti i livelli (forward-propagation), con le formule [1] e [2].
- Calcolare le  $\beta_j$  delle unità di uscita, con la formula [6].
- Calcolare le  $\beta$  di tutti i livelli (dall'ultimo al primo), con la formula [9].
- Calcolare l'influenza  $\frac{\partial E}{\partial w_{ij}}$  di ogni peso sull'errore totale, con la formula [8].
- Correggere ogni peso del valore:  $\Delta w_{ij} = -\delta \cdot \frac{\partial E}{\partial w_{ij}}$  [10]

## Cicli di calcolo

- La forward-propagation ricalcola i livelli dal primo all'ultimo, valutando, per ogni unità, le  $x_j$ ,  $F(x_j)$ ,  $F'(x_j)$  ed  $y_j$  (e azzerando le  $\beta_j$ ). Il calcolo della [1] viene eseguito una volta per ogni unità, con un ciclo sulla lista dei pesi dei collegamenti dell'unità  $j$  con le unità precedenti  $i$ .
- Per la back-propagation, il calcolo delle  $\beta_i$ , con la [9], richiede un ciclo su tutti i collegamenti dell'unità  $i$  con le unità successive  $j$ : se le unità contengono la lista dei collegamenti alle precedenti (e non alle successive), conviene eseguirlo in altro modo.
- Si esegue il calcolo su tutti i livelli  $j$ , partendo dall'ultimo.
  - Al livello  $j$  le  $\beta_j$  sono note dalla formula [6] (per l'ultimo livello) o dal calcolo del livello  $j$  eseguito precedentemente.
  - Sul livello  $j$ , si calcolano i termini  $EI_j = \beta_j \cdot F'(x_j)$  formula [7]), essendo noti i valori di  $x_j$  e  $y_j$  dalla forward-propagation.
  - Per ogni nodo del livello  $j$  si esegue un ciclo sulle sinapsi ai nodi  $i$  del livello precedente, calcolandone il contributo  $\beta_i^j = EI_j \cdot w_{ij}$  ai valori  $\beta_i$  della [9]. Nella formula [9] i valori  $EI_j$  sono già stati calcolati. I contributi  $\beta_i^j$  possono essere sommati alle  $\beta_i$ , perché tutte le  $\beta$  erano state azzerate nella forward-propagation.
  - Al termine del ciclo sui nodi del livello  $j$ , i nodi del livello precedente conterranno i valori  $\beta_i$  completi.
  - Note le  $\beta_i \equiv \beta_{j-1}$  del livello precedente, si ripete il ciclo sul livello  $j \leftarrow j - 1$ .